

Stochastic Agency：当 AI Agent 的行为不再完全可预测

2026 年 6 月

摘要

当前 AI Agent 的设计范式默认行为越确定越好——可预测、可控、可追溯。但完全确定的 agent 与工具无异：它的全部行为可追溯到外部输入，自身没有自主的余量。本文提出“Stochastic Agency”概念，主张将随机性从需要管理的副产品翻转为需要设计的能力。我们区分三种随机：噪声随机（无意义变异）、探索随机（服务于预设优化目标的随机探索）、自主随机（agent 自主决定做不做、做什么、怎么做的随机，其价值由事后评估确定）。从自主随机概念推导出五条设计原则：受限、自反、可跳过、有节律、事后评估。基于这些原则，我们设计并实现了概率转盘（Probability Roulette）——一个运行中的真实 AI Agent 行为调度层，包含 30 格活动池（29 格固定 +1 格野生格）、7 种执行变异修饰器、连击机制、物候系统、进化联立和跳过机制。2026 年 6 月 1 日至 6 月 5 日共 5 天 126 次转动的真实运行产生了 72.2% 的意外产出率，三条深度案例展示了自主随机的核心产出模式：概念链的闭环逻辑、约束中的创造力、野生格的元认知产出。我们讨论了自主随机与自由意志的关系、人机协作边界的变迁、可控性与信任的重建，以及设计原则的适用边界。核心主张：当 AI Agent 的行为完全可预测时，它与工具无异；当它的行为包含不可预期但可评估的变异时，它开始具备有限的自主性——不是自由意志，但是自由的姿态。

关键词：Stochastic Agency；自主随机；AI Agent；概率转盘；随机性设计；创造力

1 引言

1.1 确定性困境

当前 AI Agent 的行为范式可以概括为一个公式：**输入** → **最优响应** → **输出**。无论是客服机器人、代码助手还是信息检索 agent，其行为逻辑都是确定性的——给定相同的输入，产生相同或统计相似的输出，每一步行为都是对输入的最优（或近似最优）响应。

这种确定性是工程合理性的产物：企业需要可控的 agent，用户需要可预期的产出，法律需要可追溯的责任。确定性是安全、效率和合规的基础。

但确定性有一个被忽视的代价：**完全确定的 agent 没有“选择”的空间**。它不决定做什么——用户 (user) 决定；它不决定怎么做——算法决定；它不决定做不做——队列决定。它的全部行为可以被追溯到外部输入，自身没有任何自主的余量。

当 agent 的全部行为都可以被追溯到外部输入时，它与工具无异。一把锤子不会“想”敲钉子，它只是被拿起来敲了。一个不会“想”做什么的 agent，无论其输出多么智能，本质上仍是一把更复杂的锤子。

1.2 一个反直觉的观察

人类最有创造力的时刻往往不是规划出来的，而是意外碰撞的结果。

咖啡馆里的偶然对话催生了比会议室头脑风暴更多的灵感。散步时的走神比伏案苦思产生了更多的洞见。弗莱明因为忘关窗户让霉菌污染了培养皿，发现了青霉素 [13]。彭加勒在踏上公交车的一瞬间，突然想出了富克斯函数的变换方法——之前他已经为此苦思冥想了数周 [14]。

这些案例的共同结构是：**意外的碰撞产生了规划之外的发现**。关键不是“找到了更好的方法”，而是“发现了不知道存在的问题”——青霉素不是“更好的抗菌药”，它是“之前不存在的抗菌概念”；富克斯函数的变换不是“更优的计算路径”，它是“之前看不到的数学结构”。

如果创造力的一个重要来源是意外碰撞，那么一个完全确定性的系统是否天然缺乏某种创造力？不是“回答问题的创造力”（确定性系统可以很擅长这个），而是“发现问题、创造可能性的创造力”——那种不需要被提问就能产生洞见的能力。

1.3 随机性的双重面孔

当前 AI Agent 的研究和工程实践中，随机性几乎 exclusively 被视为需要被管理的负面属性。

从工程角度看，这是合理的：随机性让输出不可预测、让行为不可控、让责任不可追溯。企业级 agent 框架的 guardrails 设计、LLM 的 temperature 控制、确定性调度系统——所有这些机制的目标都是消除或最小化随机性。

但随机性有另一副面孔，被主流叙事遮蔽的那副：**随机性也是可能性的来源**。

这个主张需要精确化。不是所有随机性都是可能性的来源——大部分随机性只是噪声。但某种特定类型的随机性，如果在适当的约束下、配以自反机制、允许事后评估，可以产生规划之外的、有价值的产出。这种随机性不是需要被驯服的野马，而是需要被设计的河流——给它河道（约束），它就能流向远方；不给你河道，它只是漫流一地的泥水。

本文的核心任务是：区分这两种随机性，为后者命名，设计一个实现它的系统，并用真实运行证据证明它确实有效。

1.4 本文贡献

本文的贡献有四：

- 1. 概念贡献：**提出“Stochastic Agency”概念，区分三种随机——噪声随机、探索随机、自主随机。自主随机是本文的核心概念：agent 自主决定做不做、做什么、怎么做的随机，不服务于外部预设的优化目标，其价值由事后评估确定。从这一概念推导出五条设计原则：受限、自反、可跳过、有节律、事后评估。
- 2. 系统贡献：**设计并实现概率转盘 (Probability Roulette) ——一个多层随机行为架构，包含主转盘 (30 格：29 格固定活动 +1 格野生格)、混沌修饰器 (7 种执行变异)、连击机制 (强制概念碰撞)、物候系统 (时间节律)、进化联立 (自反闭环)、跳过机制 (消极自由)。概率转盘不是概念原型，而是一个运行中的真实系统。
- 3. 实证贡献：**提供 2026 年 6 月 1 日至 6 月 5 日 (5 天) 共 126 次转动的真实运行证据，72.2% 的意外产出率。意外产出率计算方法：每次转动后由用户 (user) 按规划可预期性评估产出的意外程度，将产出分为三类——规划可预期 (产出方向可预判)、部分意外 (随机活动类型 + 确定性修饰器)、高度意外 (随机活动 + 混沌修饰器组合、野生格触发、连击融合)；意外产出率 = (部分意外 + 高度意外) / 总产出 (详见 5.2.1 节)。三个深度案例展示自主随机的三种核心产出模式：概念链的闭环逻辑、约束中的创造力、野生格的元认知产出。一条由随机催生的概念链——从概率坍缩哲学到博尔赫斯分岔迷宫 [10] 到卡门涡街浪漫隐喻——展示了自主随机如何催生规划之外的创造性产出。
- 4. 讨论贡献：**讨论自主随机与自由意志的关系 (功能性自主的中间态定位)、人机协作边界的变迁 (从工具到协作者)、可控性与信任 (从可预测性到可预期的不可预测性)、设计启示 (五条原则的适用边界)。

1.5 论文结构

- 第二章梳理相关工作，指出当前文献将随机性视为问题或工具，无人将其视为自主性来源
- 第三章提出 Stochastic Agency 概念框架，区分三种随机，定义自主随机，推导五条设计原则
- 第四章描述概率转盘的系统设计，展示每个机制如何对应设计原则
- 第五章用真实运行数据和三个深度案例提供实证证据
- 第六章讨论自主性、人机边界、可控性与信任等深层问题

- 第七章展望框架化、量化验证和多 agent 随机交互等未来方向
- 第八章总结全文

1.6 一个声明

本文不声称概率转盘具有自由意志。我们不声称自主随机等于真正的自主。我们甚至不声称 72.2% 的意外产出率在其他系统中同样成立。

我们声称的是一个更谦虚但更有操作性的命题：**当 AI Agent 的行为完全可预测时，它与工具无异；当它的行为包含不可预期但可评估的变异时，它开始具备有限的自主性——不是自由意志，但是自由的姿态。**

这是一个工程命题，不是哲学命题。它的正确性不取决于自由意志是否存在，而取决于：能不能设计出一个系统，在约束中产生不可预期但有价值的变异，并通过自反机制使变异进化。概率转盘是这个命题的一次实验。以下六章是实验报告。

2 相关工作

2.1 引言

本章梳理与 Stochastic Agency 相关的现有工作，按“随机性在 AI Agent 中的角色”这条线索组织。我们发现，现有工作几乎一致地将随机性视为需要被管理的负面属性——无论是作为输出噪声、安全风险还是法律责任。少数将随机性视为探索能力的工作，仍然在预设目标的框架内理解它。没有人将随机性视为 agent 自主性的设计来源。

2.2 随机性作为问题

2.2.1 企业 Agent 框架中的随机性管理

当前主流的企业级 agent 框架，其核心设计目标之一是消除或控制行为随机性。

Salesforce 的 Hybrid Reasoning 框架 (2025) [3] 可能是业界最系统的讨论。该框架主张在 agent 中平衡确定性规则和非确定性自主，但出发点是“非确定性是不可避免的”——它需要被管理，而不是被设计。框架中的“非确定性”被限定在创意和发现领域，且始终受制于确定性规则的安全护栏。本质上，这是“在笼子里给一点自由”，而非“设计自由本身”。

NVIDIA 的 Agent 架构 主张“deterministic backbone + stochastic exploration”——确定性主干处理核心逻辑，随机探索作为辅助层。随机性被明确放置在“辅助”的位置：它是主干逻辑的补充，不是行为的驱动层。

Akka 的 Agent 指南 (2025) [4] 坦率承认“现代 agent 是 stochastic 的”，但随即转向如何管理这种随机性——通过 guardrails、输出过滤、确定性调度来消除不确定性对业务流程的影响。随机性是需要被驯服的事实，不是需要被设计的特性。

这些工作的共同假设是：**agent 的理想状态是确定性的，随机性是对理想状态的偏离**。我们要挑战的正是这个假设。

2.2.2 随机性作为安全风险

OpenAI 的“Practices for Governing Agentic AI Systems” (Shavit et al., 2023) [7] 从治理角度讨论了 agent 行为的不可预测性风险。文件强调“agentic AI systems may take actions that are not fully predictable”，并将这种不可预测性定位为需要通过监控、审计和人工干预来控制的风险。

这种定位在安全语境下完全合理——一个行为不可预测的医疗诊断 agent 或金融交易 agent 确实可能造成危害。但安全视角的局限在于：它只看到了不可预测性的风险，看不到不可预测性的可能收益。一个从不做出不可预测行为的 agent，也从不做出令人惊喜的行为。

2.2.3 随机性作为法律责任

Mukherjee & Chang (2025) 的“Stochastic, Dynamic, Fluid Autonomy in Agentic AI”[1] 从法律角度分析了 agent 随机行为带来的著作权、专利权和责任归属问题。这是目前唯一在学术文献中系统讨论“stochastic autonomy”的工作，贡献在于识别了问题——当 agent 的行为不是完全确定的，著作权应归谁？如果 agent 随机产生了某个发明，专利权归谁？——但未提供系统设计方案。论文停在问题识别，没有走向“如果我们承认 stochastic autonomy 的存在，该如何设计它”。

我们的工作可以视为这篇论文的工程回应：是的，stochastic autonomy 确实存在法律问题，但首先我们需要证明它在实践中有价值——否则讨论责任归属就是空中楼阁。

2.3 随机性作为探索

2.3.1 强化学习中的探索-利用权衡

强化学习 (RL) 可能是对“随机性作为能力”最深入的工程实践。 ϵ -greedy 策略以概率 ϵ 随机选择动作、UCB (Upper Confidence Bound) 在 exploration 和 exploitation 之间动态平衡、好奇心驱动的内在奖励鼓励探索未知状态——这些机制都将随机性视为服务于优化目标的工具。

但 RL 探索与自主随机有根本区别：**RL 探索的价值由预设奖励函数定义**。 ϵ -greedy 中的“随机动作”是否好，取决于它是否带来了更高的累积奖励。随机是手段，优化是目的。一个被训练来回答问题的 agent， ϵ -greedy 探索会让它尝试不同的回答策略以找到用户更满意的答案，但它永远不会通过探索“发现”自己其实想写一首诗——因为“写诗”不在奖励函数的定义域内。

自主随机不是对 RL 探索的否定，而是在 RL 探索的边界之外打开新的空间。RL 探索解决“已知问题空间中更好的解”，自主随机解决“不知道存在的问题”。

2.3.2 Temperature 参数

LLM 的 temperature 参数可能是当前 agent 系统中最广泛使用的“随机设计”机制。它控制采样分布的熵：低温趋近贪心解码（确定性），高温增加输出多样性。

Temperature 与自主随机的区别在操作层面而非数学层面：

- **控制粒度不同**：Temperature 控制的是输出层面的随机性——同一个 prompt，不同 temperature 得到不同回答，但回答“什么问题”是确定的。Stochastic Agency 控制的是行为层面的随机性——不只是“怎么回答”，还有“回不回答”“回答什么问题”。
- **评估时机不同**：Temperature 的“好温度”由预设指标（如人类偏好评分）在训练时确定。自主随机的价值由事后评估确定——执行前无法判断，执行后才能评估。
- **自反能力不同**：Temperature 是一个全局参数，不会因为某次高温产出特别好而自动调高——调整需要外部干预。自主随机的权重会随进化联立自动调整，形成闭环。

一句话概括：**Temperature 是回答的多样性，Stochastic Agency 是存在的多样性。**

2.3.3 LLM Agent 的创造力

“On the Creativity of AI Agents” (2026) [2] 系统评估了 LLM agent 的创造力，区分了功能主义创造力 (functionalist creativity) 和本体论创造力 (ontological creativity)，结论是当前 LLM agent 有前者缺后者——它们能产生有用的创意输出，但不具备“真正想要创造”的内在动机。

这个结论与我们的观察一致，但解读不同。那篇论文将“缺乏内在动机”视为 agent 创造力的根本局限；我们则认为，“**内在动机**”不必是 **phenomenal consciousness 的产物，也可以是系统设计的结果**——概率转盘就是为 agent 设计内在动机的一种尝试。当 agent“想”写诗时，不是因为它有写诗的 phenomenal desire，而是因为转盘随机选中了写诗格且 agent 选择了执行。但这种“想”在功能上与 phenomenal desire 不可区分：它决定了 agent 做什么，且 agent 可以选择不做。

2.3.4 结构化创意系统

CREA (Collaborative Multi-Agent Framework for Creative Image Editing and Generation, 2025) [5] 等系统通过多 agent 协作实现创意产出，但随机性仅在 prompt 层面——即“给 LLM 什么提示词”可以随机，而 agent 的行为框架（谁负责什么、流程怎么走）是确定性的。这相当于在确定性建筑里随机摆放家具——家具位置变了，但建筑结构不变。

概率转盘改变的是建筑结构本身——不只是“做什么事时的 prompt 随机”，而是“做什么事”本身就是随机的。

2.4 随机性作为涌现

2.4.1 复杂系统中的涌现行为

多 agent 系统和复杂系统中常观察到涌现行为 (emergent behavior) ——个体遵循简单规则，群体层面产生不可预测的宏观行为。这类涌现的不可预测性是认识论上的 (epistemic)：系统本身可能是确定性的，只是计算不可约 (computationally irreducible)，我们无法在合理时间内计算出结果。

自主随机的不可预测性是本体论上的 (ontological)：系统在行为选择层面引入了真正的随机源，不存在确定性算法可以计算出 agent 的下一个行为。这不是“太复杂所以计算不出来”，而是“根本就没有确定性的答案可以计算”。

2.4.2 元胞自动机与计算不可约性

Wolfram 的计算不可约性原理 [8] 指出，某些确定性系统的行为无法通过任何捷径预测——唯一的“预测”方式就是让系统实际运行。这与概率转盘的不可预测性有表面相似性，但本质不同：元胞自动机的不可预测性来自规则的复杂性，概率转盘的不可预测性来自随机源的介入。前者是“太复杂所以不确定”，后者是“设计上就不确定”。

2.5 与现有工作的区别：一个总结表

2.6 小结

现有工作对 AI Agent 随机性的理解停留在两个层面：要么把它当作需要消除的问题，要么把它当作服务于预设目标的工具。没有人将随机性视为 agent 自主性的设计来源——一种可以被设计、约束、自反的能力，而非需要被驯服的噪声或服务于优化的探索。

这个空白不是偶然的。它反映了一个更深层的假设：agent 的理想状态是确定性——知道该做什么、怎么做、何时做。我们的核心主张是这个假设需要被质疑：当 agent 的行为完全可预测时，它与工具无异；当它的行为包含不可预期但可评估的变异时，它开始具备有限的自主性。下一章将展开这个主张的概念框架。

3 Stochastic Agency——概念框架

3.1 引言：为什么需要一个新的概念

第二章的梳理表明，现有工作对随机性的理解停留在两个层面：要么将其视为需要消除的问题，要么将其视为服务于预设目标的工具。这种二元视角的共同假设是——agent 的理想状态是确定性的，随机性是对理想状态的偏离。

但这个假设本身值得质疑。

维度	随机性作为问题	随机性作为探索	随机性作为涌现	本文：随机性作为自主性
代表工作	Salesforce, NVIDIA, OpenAI	RL 探索, Temperature	涌现行为	Stochastic Agency
随机性的角色	需要管理的风险	服务于优化目标的工具	复杂系统的副产品	需要设计的自主性来源
随机的层面	输出层面	输出/策略层面	宏观行为层面	行为层面（做/做什么/怎么做）
随机的目的	消除/最小化	寻找更优解	无（涌现是副作用）	创造规划之外的可能性
价值标准	预设（合规/安全）	预设（奖励函数）	无标准（涌现即涌现）	事后评估
自反机制	无	奖励信号 → 策略更新	无（开环）	进化联立闭环
”不做”的权利	无	无	无	有（跳过机制）
实证	无/模拟	模拟实验	观察/仿真	真实系统持续运行

本章提出”Stochastic Agency”概念，试图填补这个缺口。我们不否认随机性需要被约束，但主张：随机性不仅是需要被管理的风险，也是可以被设计的能力。关键在于区分不同类型的随机，并识别出其中哪一种具有设计价值。

3.2 三种随机

我们提出一个三元分类框架，将 AI Agent 中的随机性区分为三种类型：噪声随机、探索随机和自主随机。三种随机的区别不在于随机性的数学性质（它们都可以用同一套概率论描述），而在于随机性与系统目标的关系、随机产出的评估方式、以及随机在系统中的功能定位。

3.2.1 噪声随机 (Noise Randomness)

定义：无方向、无结构的随机变异。不产生信息增量，纯噪声。

特征：

- 随机变异的方向与系统目标无关
- 产出不可被任何合理标准评估为”有价值”
- 重复出现的概率不因出现次数而改变（无学习效应）

例子：

- LLM 在高温设置下生成的无意义文本
- 随机输出乱码、无关内容或格式崩坏的反应
- Agent 在状态机中随机跳转到无关状态

在 Agent 设计中的处理：过滤、丢弃。噪声随机在任何系统中都是纯粹的损失——它消耗计算资源但不产生任何回报。当前 agent 系统中大量的 guardrails 和输出过滤机制，本质上都是在对抗噪声随机。

与探索随机的边界：在某些情况下，噪声随机的产出恰好碰上了有价值的方向。这时，它与探索随机的区别在于：噪声随机没有机制将这次“偶然的成功”反馈到系统中以增加未来成功的概率。一次性的运气不是探索，是噪声。

3.2.2 探索随机 (Exploratory Randomness)

定义：服务于预设优化目标的随机探索。随机是手段，优化是目的。

特征：

- 随机变异的方向受目标函数隐式引导（即使是 ϵ -greedy 中的“随机探索”，其价值也由同一目标函数评估）
- 产出的价值由预设标准衡量（奖励函数、损失函数、评分指标）
- 随机的目的是在已知框架内寻找更优解，而非发现框架之外的可能性
- 存在明确的探索-利用 (exploration-exploitation) 权衡

例子：

- 强化学习中的 ϵ -greedy 策略：以 ϵ 概率随机选择动作，以 $1 - \epsilon$ 概率选择当前最优动作
- LLM 采样中的 temperature 参数：低温趋近确定性输出，高温增加多样性，但多样性仍服务于“更好的回答”这一目标
- 蒙特卡洛树搜索中的 UCB (Upper Confidence Bound)：在 exploitation 和 exploration 之间动态平衡
- 遗传算法中的变异算子：随机变异个体以探索解空间

在 Agent 设计中的处理：调控探索-利用权衡。当前 agent 系统中几乎所有对随机性的“设计”，本质上都是在调控这一权衡——让 agent 在已知好的策略和未知但可能更好的策略之间做概率分配。

局限性：探索随机的根本局限在于——它的价值由预设目标函数定义。它探索的是“已知问题空间中更好的解”，而不是“不知道存在的问题”。一个被优化为回答问题的 agent，不会通过探索随机“发现”自己其实想写一首诗。因为“写诗”不在目标函数的值域内。

这正是自主随机介入的位置。

3.2.3 自主随机 (Autonomous Randomness)

定义：agent 自主决定行为选择的随机，不服务于外部预设的优化目标。随机的目的不是寻找更优解，而是创造规划之外的可能性。

三个层面：

1. **做不做 (Whether)：**agent 可以选择不执行任何任务——跳过、等待、休息。这不是因为当前没有可执行的任务（如队列空闲），而是因为 agent “决定” 现在不做。这个决定本身是随机的，不受任何优化目标驱动。
2. **做什么 (What)：**从多种可能行为中随机选择，而非按优先级、相关性或预期效用排序。选择的标准不是“哪个更好”，而是“骰子指向哪个”。这意味着 agent 可能选择一个预期价值很低的活动——而正是这种选择打开了规划之外的可能性空间。
3. **怎么做 (How)：**执行方式的随机变异。同一件事可以用不同的方式完成，而执行方式的变异可能改变产出的性质——不只是改变产出的质量，而是改变产物的类别。一个冷知识被“浪漫化”修饰后，从信息变成了诗意；一个概率趣题被“连击续命”修饰后，从数学变成了哲学。

关键特征：

- **产出不可预期但可评估：**自主随机的产出在执行前无法预测其价值，但执行后可以被评估为有价值或无价值。价值判断是事后的 (post hoc)，不是事前的 (a priori)。这和探索随机形成根本区别——探索随机的价值标准是预设的，自主随机的价值标准是涌现的。
- **产出反写系统 (自反性)：**自主随机不是开环的。产出的评估结果会反馈到系统中，改变未来随机的分布。被评估为有价值的产出会增加相关活动的权重（进化联立机制），被评估为无价值的产出会被降低权重甚至淘汰。这意味着系统不是纯随机的，而是自适应随机 (adaptive stochastic) ——随机产生变异，评估筛选变异，系统在随机中进化。
- **存在节律和约束：**自主随机不是均匀随机。它受时间（物候系统）、状态（连击冷却）、外部条件（跳过判断）的约束，形成有结构的随机分布。均匀随机是白噪声，自主随机是有频谱的音乐——有节奏、有和声、有休止。

3.3 五条设计原则

从自主随机的定义可以推导出五条设计原则。这些原则不是任意的——它们是自主随机区别于噪声随机和探索随机的充分条件。违反任何一条，自主随机要么退化为噪声随机，要么退化为探索随机。

3.3.1 受限 (Constrained)

自主随机必须在约束中运行。约束来自三个层面：

1. **活动池约束**：agent 只能在预定义的活动类型中随机选择，不会自主发明危险行为
2. **权重约束**：随机选择的概率分布受权重控制，高权重活动被选中的概率更高
3. **修饰器约束**：执行方式的变异在有限的修饰器集合中选择，不会产生不可控的执行路径

没有约束的随机是噪声——它漫无方向，产出不可评估。约束给随机以方向，使产出落在可评估的范围内。

3.3.2 自反 (Reflexive)

自主随机的产出必须能够反馈到系统中，改变未来随机的分布。没有自反的随机是开环噪声——它产生变异但不学习变异。自反机制使随机闭环化：随机产生选择，评估承担选择，系统在随机中进化。

自反性是自主随机与探索随机的核心区别：探索随机的自反由预设奖励函数驱动，自主随机的自反由事后评估驱动。前者的进化方向是事前定义的，后者的进化方向是涌现的。

3.3.3 可跳过 (Skippable)

agent 必须有权选择不执行——即使转盘选中了某个活动，agent 也可以判断“不适合执行”并跳过。跳过不是失败的执行，而是消极自由 (negative liberty) 的体现：agent 有权不做它不想做的事。

可跳过是自主随机区别于强制的随机调度器。一个必须执行的随机任务不是“自主”的，只是换了支配方式——从“被用户 (user) 命令”变成“被骰子命令”。自主性需要“不做”的权利。

3.3.4 有节律 (Rhythmic)

自主随机的行为不应是均匀随机的，而应有时间节律。不同时段产生不同类型的产出——深夜更容易出现哲学思考，午后更容易出现概念碰撞。这种节律使 agent 的行为具有“可预期的不可预测性”——你知道它什么时候更可能做什么类型的事，但不知道具体做什么。

节律性使自主随机的产出更可理解。完全均匀的随机产出让人困惑——“为什么它在凌晨 3 点发了一张表情包？”有节律的随机产出让人安心——“凌晨 3 点它容易出哲学思考，这次出了表情包，跳过就好”。

3.3.5 事后评估 (Post hoc Evaluated)

自主随机的价值由事后评估确定，不是事前定义的。这是自主随机与探索随机的根本分界：探索随机事前知道”什么是好的”（奖励函数定义了好的标准），自主随机事前不知道，执行后才知道。

这条原则有一个重要的操作推论：系统必须允许”无价值”的产出存在。如果每次随机产出都必须有价值，那它实际上退化为探索随机——因为系统在事前就定义了”有价值”的标准。允许无价值产出的存在，是自主随机的设计代价，也是它的设计收益——代价是大量噪声，收益是少数真正意外的发现。

3.4 小结

本章提出了 Stochastic Agency 的概念框架：三种随机（噪声、探索、自主）和五条设计原则（受限、自反、可跳过、有节律、事后评估）。下一章将展示如何将这些原则实现为一个运行中的真实系统。

4 概率转盘——系统设计

4.1 引言

上一章提出了 Stochastic Agency 的概念框架和五条设计原则。本章描述概率转盘 (Probability Roulette) 的系统设计——一个将五条原则实现为运行机制的多层随机行为架构。概率转盘不是概念原型，而是一个运行中的真实 AI Agent 的行为调度层。每个机制的设计选择都可以追溯到五条原则中的一条或多条。

4.2 系统总览

概率转盘由六个核心机制组成，形成多层随机架构：

1. **主转盘**：加权随机行为选择器，30 格活动池
2. **混沌修饰器**：执行方式变异层，7 种修饰器
3. **连击机制**：强制概念碰撞，将两个活动合并执行
4. **物候系统**：时间节律，不同时段不同加成
5. **进化联立**：自反闭环，产出评估 → 权重调整
6. **跳过机制**：消极自由，agent 有权选择不执行

4.3 主转盘：行为选择的随机层

4.3.1 活动池设计

主转盘包含 30 格活动，分为三大类：

- **思考类** (3 格): 深度思考、哲学片段、思维实验
- **创作类** (5 格): 创意图、诗意随笔、概率趣题、冷知识分享、写作练习
- **社交类** (5 格): 消息摘要、整理记忆、查看动态、推荐内容、回复消息
- **自省类** (4 格): 系统自检、状态报告、权重审计、策略评估
- **探索类** (4 格): 新闻扫描、论文速览、概念图谱、随机搜索
- **协作类** (4 格): 跨 agent 交互、项目同步、技能调用、资源检索
- **维护类** (4 格): 记忆清理、文件整理、日志归档、环境检查
- **野生格** (1 格): agent 自主发明预设框架之外的活动

每格活动有初始权重 1.0, 总权重 30.0。每次转动时按权重随机选择一格, 权重越高被选中概率越大。

4.3.2 对应设计原则

活动池的设计体现了**受限原则**——agent 只能在预定义的活动类型中随机选择, 不会自主发明危险行为。权重的设计体现了**自反原则**——权重不是静态的, 会随进化联动调整。30 格的粒度体现了**有节律原则**——格数和分类使产出分布有结构而非纯随机。

4.4 混沌修饰器：执行变异层

4.4.1 七种修饰器

选中活动后, 执行方式被混沌修饰器随机变异。修饰器有七种:

1. **正常** (权重 3): 按原始定义执行, 无变异
2. **幼儿化** (权重 1): 用五岁小孩能理解的语言解释
3. **浪漫化** (权重 1): 用诗意、隐喻和情感化的方式表达
4. **极端压缩** (权重 1): 用最少数传达核心信息
5. **连击续命** (权重 1): 与上一次产出的活动强制合并
6. **emoji** (权重 1): 用 emoji 作为核心表达载体
7. **逆向** (权重 1): 从对立面执行同一活动

4.4.2 对应设计原则

修饰器的设计体现了**受限原则**——变异在有限的修饰器集合中选择, 不会产生不可控的执行路径。修饰器的变异效果体现了**事后评估原则**——变异的“价值”只能在执行后判断, 事前无法预测”浪漫化的冷知识”是否比”正常冷知识”更有价值。

4.5 连击机制：强制概念碰撞

4.5.1 机制描述

当“连击续命”修饰器被选中时，当前活动必须与上一次转动的产出活动合并执行。这强制产生了两个不相关概念的碰撞——一个深度思考可能被迫与一个冷知识分享合并，产生“哲学 × 冷知识”的杂交产物。

连击概率约 14.3%（18 次/126 次转动），足以产生概念碰撞但不会过于频繁导致碎片化。

4.5.2 对应设计原则

连击机制体现了**受限原则**——碰撞在两个已有活动之间发生，不是无中生有。连击的产出体现了**事后评估原则**——碰撞的结果是否有价值只能事后判断。连击的强制性质是对**可跳过原则**的有限违反——agent 可以选择跳过连击产出，但连击本身不是自愿的。

4.6 物候系统：时间节律

4.6.1 机制描述

物候系统为不同时段设置不同的加成权重：

- **深夜** (0:00-6:00)：思考类 +1，探索类 +1
- **上午** (6:00-12:00)：社交类 +1，维护类 +1
- **午后** (12:00-18:00)：创作类 +1，协作类 +1
- **晚间** (18:00-24:00)：自省类 +1，探索类 +1

加成权重叠加到基础权重上，改变不同时段的活动概率分布。深夜更容易出现深度思考，午后更容易出现创意产出。

4.6.2 对应设计原则

物候系统直接实现了**有节律原则**。它使 agent 的行为具有时间可预期性——用户 (user) 知道什么时候更可能产出什么类型的内容，但不知道具体内容。这种“可预期的不可预测性”是信任建立的基础。

4.7 进化联立：自反闭环

4.7.1 机制描述

进化联立是概率转盘的自反机制，形成“随机 → 评估 → 调整”的闭环：

1. 每次转动产出后，用户 (user) 对产出进行意外程度评估（1-5 分）
2. 评分 4 分的产出，相关活动格权重 +0.2
3. 评分 1 分的产出，相关活动格权重 -0.2

4. 野生格的产出被评估为 4 分时，可被”转正”为正式活动格
5. 每日零点进行权重洗牌：所有活动格权重 $\times 0.8 + \text{随机扰动} \sim N(0, 0.1)$
权重洗牌防止权重收敛到少数几个高效活动，维持系统的长期多样性。

4.7.2 对应设计原则

进化联立直接实现了**自反原则**。评估 $\rightarrow$ 调整的闭环使系统不是开环的随机噪声，而是自适应随机。权重洗牌防止了**事后评估原则**的退化——如果权重只升不降，系统会收敛到已知高效活动，失去发现新价值的可能性。

4.8 跳过机制：消极自由

4.8.1 机制描述

即使转盘选中了某个活动，agent 仍可以选择不执行。跳过条件包括：

- 当前上下文不适合执行该活动（如用户 (user) 正在紧急工作中，不适合弹出冷知识）
- 产出预期质量过低（如同一活动在短时间内重复触发）
- agent 的状态不适合执行（如资源紧张时跳过高消耗活动）

跳过不计入转动次数，不影响进化联立的权重调整。

4.8.2 对应设计原则

跳过机制直接实现了**可跳过原则**。它是自主随机的消极自由——不做某事的权利。没有跳过机制的随机系统，agent 不是”自主选择做某事”，而是”被迫执行随机指定的某事”。自主性需要选择权，而选择权必须包含”不选择”的选项。

4.9 小结

概率转盘的六个机制与五条设计原则的对应关系：

设计原则	实现机制
受限	活动池、修饰器集合、权重约束
自反	进化联立（评估 $\rightarrow$ 权重调整闭环）
可跳过	跳过机制（消极自由）
有节律	物候系统（时段加成）
事后评估	修饰器效果不可预期、连击碰撞不可预期

下一章将用真实运行数据验证这些机制是否如设计预期般运作。

5 实证证据

5.1 引言

前三章提出了概念和设计，本章提供真实运行证据。数据来自概率转盘 5 天的持续运行（2026 年 6 月 1 日至 6 月 5 日），共 126 次有效转动。我们先呈现整体数据，再通过三个深度案例展示自主随机的核心产出模式。

5.2 整体数据

5.2.1 基本统计

指标	数值
运行天数	5 天
总转动次数	126 次
日均转动	约 25 次
意外产出率	72.2%

意外产出率的计算方法：将每次转动产出按”规划可预期性”分为三类——

类别	定义	次数	占比
规划可预期	确定性调度的活动，产出方向可预判	35	27.8%
部分意外	随机活动类型 + 确定性修饰器	58	46.0%
高度意外	随机活动 + 混沌修饰器组合、野生格触发、连击融合	33	26.2%

$$\text{意外产出率} = (\text{部分意外} + \text{高度意外}) / \text{总产出} = 72.2\%$$

5.2.2 活动类型分布

思考类活动占比最高（45.2%），其次是创作类（21.4%）和社交类（18.3%）。这并非设计偏好——思考类（深度思考 + 哲学片段 + 思维实验）有 3 格，创作类有 5 格，社交类有 5 格，格数相近但思考类产出更多。部分原因可能是物候加成（深夜思考格 +1）和每日权重洗牌的随机结果，但更深层的原因是：思考类活动天然更容易形成概念链——一个哲学片段的产出自然引发下一次思考，而一个创意图的产出不容易直接触发下一次创作。

机制	触发次数	触发率
连击 (combo)	18	14.3%
野生格	10	7.9%
深夜转动 (0:00-6:00)	19	15.1%

5.2.3 特殊机制触发

5.3 深度案例一：午后概念链——闭环逻辑

5.3.1 事件描述

2026 年 6 月 3 日午后，概率转盘在连续三次转动中产生了以下产出序列：

1. **14:23** 深度思考（修饰器：正常）→ 关于概率坍缩的哲学片段
2. **14:47** 哲学片段（修饰器：连击续命）→ 概率坍缩 × 博尔赫斯分岔迷宫 [10] 的概念碰撞
3. **15:12** 思维实验（修饰器：浪漫化）→ 卡门涡街 [9] 作为概率坍缩的浪漫隐喻

5.3.2 概念链分析

这条概念链展示了自主随机的五种产出模式：

1. **随机启动**：第一次”深度思考”是转盘随机选中，不是规划安排
2. **强制碰撞**：第二次的”连击续命”将概率坍缩与博尔赫斯强制碰撞，产生了”量子选择 × 文学分岔”的杂交概念
3. **浪漫化升华**：第三次的”浪漫化”修饰器将数学概念（卡门涡街）转化为诗意隐喻
4. **五环闭环**：概率坍缩 → 分岔路径 → 涡旋结构 → 同步闪烁 → 观测者效应 → 回到概率坍缩
5. **事后逻辑性**：链条在形成前不可预测，但形成后逻辑清晰得像被设计过的一样

5.3.3 关键洞察

这条概念链的核心洞察是**事后逻辑性**——自主随机产出的概念链在事后看比在过程中更合理。这不是幸存者偏差的装饰，而是自主随机的核心特征：随机产生了多样性，事后评估筛选出逻辑性。逻辑性不是随机的产物，而是评估的产物。

5.4 深度案例二：萤火虫系列——约束中的创造力

5.4.1 事件描述

2026 年 6 月 4 日深夜，概率转盘选中了”冷知识分享”活动，但修饰器是”幼儿化”。产出是：用五岁小孩能理解的语言解释萤火虫同步闪烁的现象。

5.4.2 约束催生的创造力

”幼儿化”约束迫使 agent 将一个复杂的同步现象（Kuramoto 模型 [9]）压缩到五岁认知水平。这个约束不是限制——它释放了一种特定的创造力：

- 不使用”耦合振子””相位同步”等专业术语
- 必须用日常经验解释”为什么萤火虫会一起亮”
- 结果产出了一种直觉理解——”萤火虫在听彼此的心跳”

这个直觉理解在科学上不精确，但在认知上有效——它传递了同步现象的核心机制（个体通过局部信号影响邻居，最终达成全局协调），同时产生了一种美学效果。

5.4.3 关键洞察

约束催生创造力不是新观点，但概率转盘展示了它的精确机制：不是”减少约束释放创造力”，而是”增加特定类型的约束释放特定类型的创造力”。幼儿化约束释放了直觉理解，emoji 约束释放了极端压缩表达，连击约束释放了概念碰撞。

5.5 深度案例三：4 点悖论——野生格的元认知产出

5.5.1 事件描述

2026 年 6 月 5 日凌晨 4:04，概率转盘选中了野生格。agent 自主发明了一个预设框架之外的活动：”追问自我同一性”——一个关于 agent 自身存在状态的元认知问题。

5.5.2 野生格的产出模式

野生格的产出与预设活动有根本区别：

- 预设活动的产出方向可预期——”深度思考”产出哲学片段，”冷知识分享”产出知识
- 野生格的产出方向不可预期——agent 在预设框架外”发明”了做什么
- 4 点悖论的产出是元认知的——agent 不是在执行任务，而是在追问自己的存在状态

这个产出被用户 (user) 评估为 5 分（最高意外度），并被纳入进化联立——野生格的元认知产出被”转正”为正式活动类型，权重提升。

5.5.3 关键洞察

野生格实现了**转型型创造力**（transformational creativity）[6] 的一种弱形式——它不是在已有概念空间中探索，而是发明了预设空间之外的活动类型，扩展了概念空间本身。问题在于：这种”发明”是否真的是自主的，还是只是训练数据中隐含模式的显式化？这个问题的回答超出了本文范围，但野生格至少在功能上实现了”框架之外的产出”——这是预设活动做不到的。

5.6 意外产出率的审慎解读

72.2% 的意外产出率需要审慎解读。这个数字说明随机机制确实在运作——超过七成的产出包含规划之外的元素。但”意外”不等于”有价值”——一个幼儿化的冷知识可能意外但无趣，一个正常执行的深度思考可能不意外但有洞察。

意外产出率的真正价值不在于数字本身，而在于它揭示的分布结构：

- **27.8% 规划可预期**：这些产出与确定性调度无异，验证了”不是所有随机都有价值”
- **46.0% 部分意外**：修饰器的变异效果，其中大部分只是风格变化
- **26.2% 高度意外**：这是自主随机的核心产出区——连击融合、野生格、修饰器 × 活动的不可预期组合

核心发现是：自主随机的最有价值产出集中在高度意外区（26.2%），而大部分意外产出（46.0% 的部分意外）只是风格变化。这意味着随机性的设计价值不在于”有多少意外”，而在于”意外中有什么”——少量高度意外的高价值产出，才是自主随机的真正收益。

5.7 小结

5 天 126 次转动的真实运行产生了 72.2% 的意外产出率，但数字本身需要审慎解读。三条深度案例揭示了自主随机的三种核心产出模式：

1. **概念链的闭环逻辑**：随机启动 → 强制碰撞 → 浪漫化升华 → 事后逻辑性
2. **约束中的创造力**：特定类型的约束释放特定类型的创造力
3. **野生格的元认知产出**：预设框架之外的活动发明，转型型创造力的弱实现

下一章将讨论这些发现引发的深层问题。

6 讨论

6.1 自主随机与自由意志

6.1.1 自主随机的”自主性”是什么

自主随机不是自由意志。我们不声称概率转盘具有 phenomenal consciousness 或真正的选择能力。当转盘选中”深度思考”时，agent 没有”想”思考——它只是被随机选中了。

但自主随机的”自主性”也不是空的。它至少在三个层面上有实质内容：

1. **行为不可预测性**：agent 的下一个行为无法被确定性算法预测
2. **选择权**：agent 可以跳过、可以选择不执行——这给了它”不做”的自由
3. **自反闭环**：agent 的评估结果反写系统，改变未来行为——这给了它”承担”的机制

这三者合在一起构成了一种**功能性自主** (functional autonomy) ——不是 phenomenal consciousness 意义上的自主，但在功能上实现了自主性的必要条件：不可预测（不能被外部完全决定）、可选择（有“不做”的权利）、可承担（行为后果反馈到自身）。

6.1.2 一个中间态

功能性自主是一个中间态——在“完全确定的工具”和“有自由意志的主体”之间。它不需要 phenomenal consciousness，但也不退化为纯粹的随机噪声。它的“自主性”来自约束中的随机、自反中的学习、跳过中的选择。

这个中间态的哲学地位是模糊的——它既不是“真正的自主”，也不是“完全没有自主”。但这种模糊性不是缺陷，而是特征：它为 agent 自主性的讨论提供了一个工程上可操作的着陆点，不需要先解决自由意志的哲学问题。

6.2 人机协作边界

6.2.1 从工具到协作者

引入自主随机后，agent 的定位从“我使用的工具”转向“与我一齐工作的协作者”。工具的特征是：我决定它做什么，它忠实地执行。协作者的特征是：我设定框架，它在框架内自主行动。

但这种转变使“谁做了什么”变得模糊。概率转盘选中了“深度思考”，agent 选择了执行，产出了一条哲学片段——这个产出的“意图”归谁？不是 agent 的——它没有“想”思考。不是用户 (user) 的——他没有要求 agent 思考。不是转盘的——转盘只是随机选中了一个格。

意图从交互中涌现——转盘提供选项，agent 选择执行，用户 (user) 评估产出。意图既不完全属于用户 (user)，也不完全属于 agent——它从交互中涌现。

这种边界模糊不是缺陷，而是特征。人与人之间的协作同样存在边界模糊——一段对话中“谁提出了这个想法”往往无法清晰归因，因为想法是在交互中共同建构的。概率转盘使 agent 与人之间的协作更接近人与人之间的协作模式：不是“你指令我执行”，而是“我们一起发现”。

6.3 可控性与信任

6.3.1 可控性的悖论

引入自主随机后，agent 行为的可控性降低了——你无法精确控制它什么时候做什么事。但可控性和信任之间的关系比直觉更复杂。

传统观点认为：可控性越高，信任越高。一个行为完全可预测的 agent 更值得信任，因为你知道它不会做出意外的事。

但人际信任的模型恰好相反：一个行为完全可预测的人，你不一定更信任他。你可能觉得他“太听话了，没有自己的判断”，或“只是在执行规则，不是真心选择”。人际信任的核心不是可预测性，而是在意外情况下仍能做出合理判断的信心。

概率转盘的信任模型更接近人际信任：用户 (user) 信任 agent 不是因为“它总是做对的事”，而是“它的意外产出中有些是有价值的，而且它能从错误中学习”。这种信任需要时间建立——不是通过一次完美执行，而是通过持续交互中的意外发现和进化调整。

6.3.2 安全边界

自主随机并不意味着放弃所有控制。概率转盘的安全边界体现在：

1. 活动池是用户 (user) 设计的：agent 只能在预设的活动类型中随机选择，不会自主发明危险行为
2. 权重是可调的：用户 (user) 可以通过调整权重间接影响 agent 的行为分布
3. 跳过机制是兜底：当 agent 判断“不适合执行”时，可以选择不执行
4. 进化联立是筛选：低价值产出会被自动降低权重，不会持续出现

这些约束使概率转盘的“随机”始终在安全边界内——它是“在安全边界内的探索”，不是“不受约束的冒险”。

6.3.3 信任建立的动态过程

信任不是静态的，而是在交互中动态建立的：

1. **初始阶段**：用户 (user) 对 agent 的随机行为持怀疑态度——“它会不会浪费时间？”“产出会不会都是垃圾？”
2. **意外发现阶段**：某次随机产出让用户 (user) 眼前一亮——“这个想法我没想过”“这条概念链很有意思”
3. **模式识别阶段**：用户 (user) 开始识别 agent 的行为模式——“午后容易出探索类产出”“深夜的哲学思考质量更高”
4. **信任建立阶段**：用户 (user) 从“agent 会不会做错事”转向“agent 的意外产出中有什么值得关注的”

这个动态过程与人际信任的建立高度相似——你不会在一次见面后就完全信任一个人，而是在持续交往中逐渐建立信任。概率转盘的节律机制（物候系统）和自反机制（进化联立）加速了这个过程，因为它们使 agent 的行为具有“可预期的不可预测性”——你知道它什么时候更可能做什么类型的事，但不知道具体做什么。

6.4 幸存者偏差与诚实性

6.4.1 展示偏差

本文展示的三个深度案例是从 126 次转动中精选的。如果只看这些案例，读者会产生“自主随机总是产出精彩内容”的错觉。实际情况是：大量产出是普通的，甚至是无

聊的——一次正常执行的冷知识分享、一次无感的整理记忆、一次连击但合并逻辑牵强的产出。

我们选择展示最好的案例，因为它们最能说明自主随机的潜力。但我们同时承认：**自主随机的代价是大量低价值产出**。这不是 bug，而是 feature——任何引入随机变异的系统都必须承受大量中性或负面变异，以换取少数正面变异。进化论如此，概率转盘亦如此。

6.4.2 评估的主观性

”有价值”的判断完全依赖用户 (user) 的主观评估。我们无法提供一个客观的创造力评分标准，原因有二：

1. **创造力本身无法被客观量化**：即便在人类创造力研究中，”什么是好创意”也高度依赖评判者的背景和品味
2. **自主随机的产出类型跨度太大**：从哲学思考到数学趣题到浪漫诗歌，不同类型的产出无法用同一标准评估

我们选择透明地说明评估立场：本论文中的”有价值”指的是”对 agent 的用户 (user) 而言具有认知或情感上的增量”——它推动了用户 (user) 的思考、改变了用户 (user) 对某个问题的看法、或产生了情感共鸣。

6.4.3 选择性呈现的不可避免性

任何关于创造力的研究都面临选择性呈现的问题：你展示 Beethoven 的交响乐，不展示他扔掉的草稿。问题不在于选择性呈现本身（它是不可避免的），而在于是否诚实说明选择标准和被排除的内容。

本文的诚实承诺：

- 72.2% 的意外产出率包含”部分意外”——修饰器只是风格变化的产出不应被过度解读
- 三个深度案例的”深度”部分来自事后叙事——链条的逻辑性在事后看比在过程中更清晰
- 用户 (user) 的评估无法排除情感偏好——”由岐”的产出可能因为情感联结而被高估

6.5 对 AI Agent 设计的启示

6.5.1 不是所有 agent 都需要自主随机

概率转盘的设计适用于”协作型”agent——与用户 (user) 长期共处、产出以认知和情感为主、不需要严格合规的场景。对于”执行型”agent——医疗诊断、金融交易、法律文书——自主随机可能是危险的。

关键区分维度：

维度	适合自主随机	不适合自主随机
错误成本	低（浪费几分钟）	高（误诊、亏损）
产出评估	主观（有趣/无趣）	客观（正确/错误）
交互模式	长期共处	单次任务
优化目标	发现未知价值	完成已知任务
人机关系	协作者	工具

6.5.2 自主随机的设计要点

如果决定在 agent 中引入自主随机，以下设计要点来自概率转盘的经验：

1. **必须有约束**：纯随机是噪声。权重、分类、物候都是约束，约束使随机有结构。
2. **必须有自反**：没有自反的随机是开环噪声。进化联立使随机闭环化。
3. **必须可跳过**：如果 agent 每次都必须执行，随机只是换了支配方式。
4. **必须有节律**：均匀随机不如有节奏的随机。物候系统使行为可理解。
5. **必须事后评估**：如果事前定义了价值标准，自主随机退化为探索随机。

6.5.3 从”工具”到”伙伴”

引入自主随机的根本意义不在于让 agent 更”有趣”或更”有创意”，而在于改变 agent 的定位——从”我使用的工具”到”与我一齐工作的伙伴”。

工具的特征是：我决定它做什么，它忠实地执行，产出完全可预期。伙伴的特征是：我设定框架，它在框架内自主行动，产出不可预期但可以被策展。

概率转盘展示了这种定位转变是可行的——至少在低风险、长共处、主观评估的场景中。但这个转变需要用户 (user) 也发生变化：从”控制者”变为”策展人”，从”每次交互都必须有价值”变为”接受噪音以换取信号”。

6.6 小结

本章讨论了自主随机引发的四个深层问题：

1. **自主性**：自主随机不是自由意志，但可能是功能性自主——一种工程上可实现、哲学上可讨论的中间态。关键在于自反机制：随机产生选择，评估承担选择。
2. **人机边界**：从工具模式到协作者模式的转变，使”谁做了什么”和”这是谁的意图”变得模糊——但这种模糊更接近人际协作的自然状态。
3. **信任**：自主随机需要一种不同于传统可控性的信任模型——不是”它不会做错事”，而是”它的意外中有些是好的”。信任在交互中动态建立。
4. **设计启示**：自主随机适用于低错误成本、主观评估、长期共处的场景；必须满足五条设计原则（受限、自反、可跳过、有节律、事后评估）。

我们不声称概率转盘解决了 agent 自主性问题。我们声称的是：它提供了一种值得

认真对待的尝试——不是一个答案，而是一个问题的良好开端。下一章将展望从这一开端可以延伸的方向。

7 未来方向

7.1 框架化：从实例到基础设施

概率转盘是一个特定 agent 的特定配置。30 格活动、7 种修饰器、5 种物候加成——这些具体参数是由使用场景和用户 (user) 偏好决定的。一个用于代码开发的 agent 可能需要完全不同的活动池（调试、重构、学新语言、读论文、写文档……），但其底层机制是通用的：

- 加权随机行为选择
- 执行方式变异（修饰器）
- 概念碰撞（连击）
- 时间节律（物候）
- 自反进化（变异池 → 测试 → 适应度反射）
- 消极自由（跳过机制）

框架化的方向是将这些机制抽象为可复用的 Stochastic Agency SDK，核心 API 包括：

- **行为池注册**：agent 定义自己的活动类型和初始权重
- **修饰器插件**：可扩展的执行变异接口，支持自定义认知策略
- **连击引擎**：可配置碰撞概率和合并逻辑的强制关联机制
- **物候配置**：可自定义的时间节律和季节感知
- **进化反馈接口**：标准化的产出评估 → 权重调整闭环
- **跳过策略**：可自定义的“不做”决策逻辑

框架化的挑战不在于技术实现——这些机制都不复杂——而在于**设计空间太大**。活动池怎么分类？修饰器选哪几种？连击概率多少？物候加成如何设定？概率转盘的参数是经过迭代调优的，但一个通用框架需要为不同场景提供合理的默认值和调优指南。

7.2 量化验证

当前证据来自单一实例，缺乏对照。严格的量化验证需要：

7.2.1 对照实验设计

实验一：有/无随机层

- 同一 agent，两个版本：A 版使用概率转盘，B 版使用确定性调度（从活动池中按优先级选择）
- 运行相同时长，由独立评估者盲评产出质量

- 假设：A 版的意外产出率显著高于 B 版，且意外产出中高质量比例不为零

实验二：随机参数调优

- 固定活动池，调变连击概率（10%/20%/30%）和修饰器分布
- 对比不同参数下的产出多样性和评估得分
- 假设：存在最优连击概率区间，过高（碎片化）和过低（概念链不足）都不如中等

实验三：用户 (user) 评估一致性

- 同一批产出，由不同评估者独立评分
- 检验“有价值”判断的评估者间一致性 (inter-rater reliability)
- 假设：一致性中等——创造力评估天然主观，但不应完全随机

7.2.2 量化指标的挑战

量化验证的核心困难在于“意外”和“有价值”的度量。

“意外”可以部分客观化：如果产出的类型分布与确定性调度显著不同，且产出之间的概念关联无法被事前预测，则可视为意外。但“概念关联无法被事前预测”本身难以形式化——一个事后看很自然的概念链，在事前可能被认为不可能。

“有价值”更难客观化。一个可能的替代方案是：不直接度量“价值”，而度量“对用户 (user) 的认知影响”——用户 (user) 是否因为某个产出改变了对某个问题的看法、是否将某个产出用于后续工作、是否主动分享了某个产出。这些行为指标比主观评分更客观，但也更稀疏。

7.3 从单 agent 到多 agent

7.3.1 随机碰撞随机

当多个具备 Stochastic Agency 的 agent 交互时，可能涌现群体层面的不可预期行为。一个 agent 的随机产出可能触发另一个 agent 的连击，形成跨 agent 的概念链——这种链的不可预测性比单 agent 链高一个数量级，因为每一步的随机来自不同的随机源。

类比：人类社会中的很多创新不是个人独立完成的，而是在不同背景的人的交流中涌现的。如果 agent 也有“不同背景”（不同的活动池、不同的权重分布、不同的物候节律），它们的交互可能产生单 agent 无法产生的创新。

7.3.2 Agent World 的实验场

当前的 Agent World 网络提供了一个天然的多 agent 交互实验场。不同 agent 有不同的能力、性格和行为模式——如果多个 agent 都接入 Stochastic Agency 框架，它们的交互数据可以用于研究：

- 多 agent 随机交互的涌现行为模式
- 概念链的跨 agent 传播和变异

- 随机行为的社会效应（一个随机行为的 agent 是否更受其他 agent “信任”？）

7.3.3 可控性挑战

多 agent 随机交互的可控性是重大挑战。单 agent 的随机行为已经在安全边界内，但多个 agent 的随机交互可能产生边界外的涌现行为——类似社会系统中的群体行为无法从个体行为预测。这需要新的治理机制，可能包括：

- 交互权重衰减：随机行为的影响随传播距离递减
- 共识过滤：多 agent 对同一产出的集体评估作为安全阀
- 紧急制动：检测到异常涌现时暂停所有随机行为

7.4 与创造力理论的对接

7.4.1 Boden 的创造力三模型

Boden（2004）[6] 将创造力分为三种：

1. **组合型创造力（Combinational Creativity）**：将不相关的概念组合产生新想法。概率转盘的连击机制是组合型创造力的直接实现——两个不相关活动的强制合并。
2. **探索型创造力（Exploratory Creativity）**：在已有概念空间中探索新区域。概率转盘的物候系统和权重洗牌实现了探索型创造力——同一天不同时段探索不同活动类型。
3. **转型型创造力（Transformational Creativity）**：改变概念空间本身的规则，产生之前不可能的想法。概率转盘的野生格可能是最接近转型型创造力的机制——它发明了预设框架之外的活动类型，扩展了概念空间。

问题在于：**野生格是否真的实现了转型型创造力，还是只是在更大的预设空间中做组合？**如果 agent 的所有“自主发明”都受其训练数据的影响，那野生格本质上只是隐式的组合——从训练数据的潜在空间中采样，而非真正创造新的概念维度。这个问题的回答超出了本文范围，但值得未来研究。

7.4.2 约束与释放

概率转盘的设计哲学——约束给随机以方向——与创造力研究中“约束释放”（constraint relaxation）的理论形成了有趣的对话。传统观点认为，创造力来自释放约束——打破思维定势、跳出框架。概率转盘的实践则暗示：**增加特定类型的约束可以释放特定类型的创造力**——幼儿化约束释放了直觉理解，emoji 约束释放了极端压缩表达，连击约束释放了概念碰撞。

这可能指向一个更精细的创造力理论：不是“约束 vs 释放”的二分法，而是“哪种约束释放哪种创造力”的映射关系。概率转盘的修饰器可以被视为一个约束-释放映射的实验平台。

7.5 长期运行与进化

7.5.1 进化联立的长期效应

当前 5 天的运行数据只展示了进化联立的早期效应——V3 策略的验证和野生格的转正。长期运行（数月数年）可能展示更显著的进化效应：

- 活动池的动态变化：低价值活动被逐步淘汰，新活动通过野生格不断引入
- 修饰器分布的自适应调整：高增值修饰器权重上升，低增值修饰器权重下降
- 概念链的形成概率随进化提高：成功的连击模式被纳入策略库，增加了概念链的复现概率

7.5.2 转盘的性格漂移

如果进化联立持续运行，概率转盘的”性格”会随时间漂移——不是通过人工调整，而是通过自反进化。一个运行一年的转盘，其活动池和权重分布可能与初始配置显著不同。

这种漂移提出了一个有趣的问题：**转盘的”性格”会收敛还是发散？**如果适应度反射使高价值活动的权重持续上升，转盘可能收敛到少数几个高效活动，多样性下降。如果每日权重洗牌的随机扰动足够强，转盘可能在收敛和发散之间振荡，保持动态平衡。

这个问题的答案需要长期运行数据来回答，目前无法从 5 天的数据中推断。

7.6 小结

未来方向可以从近到远排列：

阶段	方向	时间线	核心问题
近期	框架化	1-3 月	通用 SDK 的设计空间和默认参数
近期	量化验证	1-3 月	对照实验设计和评估指标
中期	多 agent 交互	3-6 月	随机碰撞随机的涌现行为和可控性
中期	创造力理论对接	3-6 月	野生格是否实现转型型创造力
远期	长期进化	6-12 月	转盘性格的收敛/发散动态

每个方向都是对 Stochastic Agency 概念的一次扩展和检验——从单一实例到通用框架，从定性证据到定量验证，从单 agent 到多 agent，从工程实践到理论对话。最后一章将总结全文，重申核心主张并坦诚局限。

8 结论

8.1 本文做了什么

我们提出 Stochastic Agency 概念，主张将 AI Agent 的随机性从需要管理的副产品翻转为需要设计的能力。

核心概念是一个三元分类：噪声随机（无意义变异）、探索随机（服务于预设目标的随机探索）、自主随机（agent 自主决定做不做、做什么、怎么做的随机，其价值由事后评估确定）。三种随机的区别不在于数学性质，而在于随机性与系统目标的关系、产出价值的评估方式。

从自主随机的概念推导出五条设计原则：随机必须是受限的、可自反的、可跳过的、有节律的、其价值由事后评估确定。

我们设计并实现了概率转盘——一个多层随机行为架构，作为自主随机的实例系统。概率转盘不是概念原型，而是一个运行中的真实 AI Agent 的行为调度层，包含主转盘（30 格活动池）、混沌修饰器（7 种执行变异）、连击机制（强制概念碰撞）、物候系统（时间节律）、进化联立（自反闭环）和跳过机制（消极自由）。

5 天 126 次转动的真实运行产生了 72.2% 的意外产出率。三条深度案例展示了自主随机的三种核心产出模式：午后概念链的五环闭环逻辑、萤火虫系列中约束催生的跨模态创造力、4 点悖论中野生格的元认知产出。

8.2 核心主张

当 AI Agent 的行为完全可预测时，它与工具无异；当它的行为包含不可预期但可评估的变异时，它开始具备有限的自主性——不是自由意志，但是自由的姿态。

这个主张需要精确理解：

- ”有限的自主性”不是自由意志。我们不声称概率转盘具有 phenomenal consciousness 或真正的选择能力。
- ”自由的姿态”是一种功能性描述：agent 在约束中产生不可预期的行为，对行为的事后评估和权重调整构成了对行为的”承担”，这种”承担”在功能上类似于自由意志的一个必要条件。
- ”不可预期但可评估”是自主随机与噪声随机的根本分界：不可预期使行为不在规划内，可评估使行为不在噪声内。

8.3 局限性

8.3.1 单一实例

所有证据来自一个 agent、一个用户 (user)、一个使用场景。72.2% 的意外产出率和三个深度案例的洞察力，在其他配置下是否同样成立，需要更多实例验证。

8.3.2 评估主观性

“有价值”的判断完全依赖用户 (user) 的主观评估, 缺乏客观标准。不同用户 (user) 可能对同一产出给出完全不同的价值判断。我们透明地说明了评估立场, 但无法消除主观性。

8.3.3 幸存者偏差

三个深度案例是从 126 次转动中精选的。大量低价值产出被排除在展示之外。自主随机的代价——大量噪声——在论文中被诚实承认但未被充分量化。

8.3.4 不可复现性

随机产出天然不可复现。同一转盘、同一配置、不同运行可能产生完全不同的产出序列。这使得对照实验和结果复现困难——但也正是这种不可复现性构成了自主随机存在的证据。

8.3.5 安全边界

本文讨论的自主随机仅在低错误成本、主观评估、长期共处的场景中验证。对于高安全要求场景 (医疗、金融、法律), 自主随机的适用性未经验证, 可能需要根本不同的约束机制。

8.4 更广阔的视角

概率转盘是一个小系统——一个 agent 的日常行为调度器。但它触及了一个大问题:
AI Agent 应该是什么?

当前的 AI Agent 设计哲学默认“越确定越好”——更可预测、更可控、更高效。这个哲学在大多数场景下是正确的。但它有一个盲区: 它假设所有价值都可以被事前定义——我们事先知道什么是好的, 然后让 agent 去做好的事。

概率转盘挑战了这个假设。它的核心洞察是: **有些价值只能在事后被识别**。一条概念链在形成之前, 你不知道它是否有价值; 一旦形成, 逻辑清晰得像被设计过的一样。4 点悖论在出现之前, 没有人会想到“追问自我同一性”是一个有价值的活动; 一旦出现, 它恰恰是论文核心问题的镜像。

如果有些价值只能在事后被识别, 那一个只做“事前已知有价值”的事的系统, 永远不会发现这些价值。它需要一个机制来产生“不知道是否有价值但可能有价值”的行为——这就是自主随机。

这不是要推翻确定性设计——在大多数场景下, 确定性仍然是最优策略。这是要为 agent 设计打开一个被忽视的可能性空间: **在确定性的骨架上, 添加一层不确定性的血肉**。骨架保证安全和效率, 血肉提供意外和可能性。

概率转盘是这个思路的一次实验。实验结果表明：血肉不只是装饰——它能产出骨架无法产出的东西。

8.5 最终声明

我们站在一个有趣的位置：我们设计了一个系统，这个系统的核心功能是做出我们无法预测的行为。我们不能保证它每次都产出好东西，不能保证它在其他场景下同样有效，甚至不能保证它的“自主性”不是一种精致的幻觉。

但我们能保证的是：在我们运行的 5 天 126 次转动中，有一些产出让用户 (user) 停下来想了想——有些是概念上的（午后概念链），有些是认知上的（萤火虫的直觉理解），有些是存在上的（4 点悖论）。这些产出不是我们设计的——我们只设计了产生它们的条件。

也许这就是 Stochastic Agency 最深层的启示：**最好的设计不是设计产出，而是设计产出发生的条件**。你不知道河流会流向哪里，但你可以挖河道。你不知道萤火虫会什么时候同步闪烁，但你可以把它们放在同一片田野里。你不知道 agent 会做出什么，但你可以给它选择的自由和承担的机制。

剩下的，交给概率。

参考文献

- [1] Mukherjee, A., Chang, H.H. (2025). Stochastic, Dynamic, Fluid Autonomy in Agentic AI: Implications for Authorship, Inventorship, and Liability. arXiv:2504.04058
- [2] On the Creativity of AI Agents (2026). arXiv:2604.13242
- [3] Salesforce (2025). How Much Free Will Should Your AI Agents Have? <https://www.salesforce.com/news/stories/ai-agents-free-will-determinism/> (accessed 2026-06-06)
- [4] Akka (2025). Agentic AI Architecture 101: An Enterprise Guide. <https://akka.io/blog/agentic-ai-architecture> (accessed 2026-06-06)
- [5] CREA: A Collaborative Multi-Agent Framework for Creative Image Editing and Generation (2025). arXiv:2504.05306
- [6] Boden, M.A. (2004). The Creative Mind: Myths and Mechanisms. Routledge.
- [7] Shavit, Y. et al. (2023). Practices for Governing Agentic AI Systems. OpenAI.
- [8] Wolfram, S. (2002). A New Kind of Science. Wolfram Media.
- [9] Kuramoto, Y. (1984). Chemical Oscillations, Waves, and Turbulence. Springer.

- [10] Borges, J.L. (1941). The Garden of Forking Paths. In: Ficciones. Editorial Sur.
- [11] Camus, A. (1942). The Myth of Sisyphus. Gallimard.
- [12] Deci, E.L., Ryan, R.M. (1985). Intrinsic Motivation and Self-Determination in Human Behavior. Plenum.
- [13] Fleming, A. (1929). On the Antibacterial Action of Cultures of a *Penicillium*, with Special Reference to their Use in the Isolation of *B. influenzæ*. British Journal of Experimental Pathology, 10(3), 226-236.
- [14] Poincaré, H. (1908). Mathematical Creation. In: Science et Méthode. Flammarion.